Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный университет имени М.В.Ломоносова»

Казахстанский филиал
Направление 01.03.02 «Прикладная математика и информатика»

Шахпутов Асылхан Ерболатулы

Анализ тональности чатов на казахском языке

Курсовая работа

Научный руководитель:
доцент, Смирнов И.Н.
Допустить к защите:
заведующий кафедрой
Л.В. Крицков

_____
(подпись зав.кафедрой)
«_____» _____ 2024 г.

Астана, 2024

Содержание

Введение **3**

1 Анализ тональности текста: концепция, методы **4**

1.1 Понятие и сущность. Виды классификации текста 4

1.2 Алгоритмы классификации 5

1.2.1 Logistic Regression 5

1.2.2 Методы на основе ANN (искусственных нейронных сетей): CNN, RNN 6

1.3 Предобработка и методы векторизации текстовых данных 8

1.4 Оценка модели 10

2 Практическая часть **13**

2.1 Сбор данных 13

2.2 Предобработка данных 13

2.3 Векторизация и анализ данных 15

2.4 Оценка модели 16

2.5 Результаты 17

3 Заключение **19**

Список литературы **20**

Введение

В современном информационном обществе модели машинного обучения, использующие обработку текстов, играют важную роль в таких областях, как обработка естественного языка, компьютерное зрение и автоматическая классификация. Анализ тональности текста является одной из ключевых задач обработки естественного языка, направленной на определение эмоциональной окраски текста. Он находит широкое применение в маркетинге, социологии, политологии и других сферах, где необходимо анализировать мнения и настроения пользователей. В условиях стремительного роста объема текстовой информации, инструменты анализа тональности становятся все более востребованными.

С развитием интернета и социальных сетей значительно возросла необходимость в анализе текстов на различных языках, включая казахский. В то время как для таких языков, как английский и русский, существует множество инструментов и методов анализа тональности, для казахского языка таких ресурсов недостаточно. Это связано с особенностями казахского языка и ограниченным количеством доступных данных.

Анализ тональности текстов на казахском языке имеет важное значение для многих сфер, включая государственное управление, бизнес и образование. Он позволяет понимать настроение и мнение пользователей, что может быть полезным для принятия решений и улучшения взаимодействия с аудиторией.

Целью данной работы является разработка и оценка методов анализа тональности текстов на казахском языке с использованием современных технологий машинного обучения. Для достижения поставленной цели необходимо решить следующие задачи:

- сбор и предобработка текстовых данных на казахском языке из различных источников,
- разработка общего конвейера для нормализации, токенизации и удаления пунктуации для казахского языка,
- построение и оценка моделей машинного обучения для классификации тональности текстов,
- предложение направлений для дальнейших исследований и улучшения модели.

1. Анализ тональности текста: концепция, методы

1.1. Понятие и сущность. Виды классификации текста

Выраженная в тексте эмоциональная оценка называется тональностью/сентиментом текста. В жизни человек оценивает окружающий мир, используя множество параментров. В итоге, распределяя в определенно нагруженные группы: высокий/низкий, цветной/черно-белый и т.д. Однако для упрощения, можно представить эмоциональную оценку в виде шкалы ”позитивный-негативный”. Также для более точного определения тональности добавляют третью группу — нейтральную. Существует и другие виды классификаторов: многоклассовые классификаторы, классификаторы основанные на числовой шкале (0-1; 0-100). Таким образом, основная задача — определить сентимент отзывов по какой-либо тематике(техника, спорт, культура, товар и пр.).

В современное время читателей интересует выяснить отношение сентимента к конкретному объекту, упоминаемому в тексте, а также отношение субъекта высказывания к обсуждаемому объекту.

Объект тональности — объект, относительно которого выражается эмоциональная оценка. Этот вид сентимент-анализа называется объектной тональностью *object-based*. Еще одним направлением сентимент-анализа является выявление позитивности/негативности атрибутов объекта тональности (*feature-based*), то есть в комментарии описывается объект с различными оценочными параметрами, и результатом сентимента является общая оценка объекта.

Носителем выраженной в тексте эмоциональной оценки также обычно является вполне определённое лицо, в общем случае это автор текста. Однако если автор текста ссылается на чьё-нибудь мнение или цитирует высказывание другого человека, то **субъектом тональности** будет тот, на чьё мнение ссылаются.

Таким образом, тональность высказывания определяется 3 компонентами: субъектом тональности, объектом тональности и тональной оценкой. В дальнейшем будет предполагаться, что субъектом тональности является автор текста/статьи/отзыва.

1.2. Алгоритмы классификации

Существует множество методов к подходу классификации: экспертный, rule-based, обучение с учителем, обучение без учителя. В частности, в данном разделе работы рассмотрено несколько алгоритмов классификации, которые широко используются в области обработки текстов и анализа естественного языка. Особое внимание будет уделено алгоритмам Logistic Regression и CatBoost, а также рассмотрены методы на основе искусственных нейронных сетей: CNN (Convolutional Neural Network), RNN (Recurrent Neural Network).

Пусть $P(c_i|d)$ – вероятность того, что документ, представленный вектором $d = (t_1, , t_n)$, соответствует категории $c_i \in \{1; |C|\}$. Задача классификатора заключается в нахождении значений c_i и d, при которых значение вероятности $P(c_i|d)$ будет максимальным:

$$F(d) = \arg\max_{c_i \in C} P(c_i|d).$$

1.2.1. Logistic Regression

Логистическая регрессия (logistic regression) является линейным методом классификации, который используется для предсказания вероятности возникновения определенного события на основе значений набора признаков. Для этого вводится зависимая переменная y, которая принимает только два значения - обычно 0 и 1, соответствующие непроизошедшему и произошедшему событию, а также набор независимых переменных $x_1, ..., x_n$, значения которых используются для вычисления вероятности принятия значений зависимой переменной. В случае классификации документов, категория c_i выступает в качестве зависимой переменной, а документы $d_1, ..., d_n$ - в качестве независимых переменных.

Логистическая регрессия может быть представлена в виде однослойной нейронной сети с сигмоидальной функцией активации. Веса этой нейронной сети соответствуют коэффициентам логистической регрессии, а вес поляризации представляет собой константу в регрессионном уравнении:

$$P\{y = 1|x\} = f(z).$$

Преимущества метода:

- является одним из наиболее качественных;
- поддерживает инкрементное обучение, что позволяет обновлять модель по мере получения новых данных;

- реализация алгоритма метода относительно проста программно.

Недостатки метода:

- имеет сложную интерпретируемость параметров, что может затруднить понимание внутреннего функционирования алгоритма;
- неустойчив к выбросам в исходных данных, что может привести к непредсказуемому поведению модели.

1.2.2. Методы на основе ANN (искусственных нейронных сетей): CNN, RNN

Существует множество различных типов нейронных сетей, среди которых основные включают в себя сети прямого распространения, сверточные сети, рекуррентные сети, радиально-базисные функции и самоорганизующиеся карты. Веса в нейронных сетях могут быть настроены как фиксированные, так и динамические.

Классическая нейронная сеть прямого распространения (Feed Forward Back Propagation, FFBP) состоит из входного слоя, выходного слоя и промежуточных слоев. Сигнал проходит последовательно от входного слоя нейронов через промежуточные слои и достигает выходного слоя. Примером такой структуры является многослойный перцептрон (см. рис. 1).

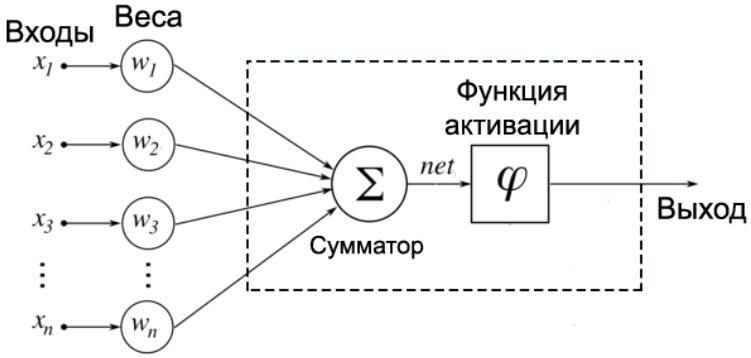

Рисунок 1. Общий вид нейронной сети

При использовании нейронной сети прямого распространения для классификации документа d_i, веса признаков документа передаются на соответствующие входы сети. Активация распространяется через сеть, и значения, полученные на выходах, представляют результат классификации. Одним из стандартных методов обучения такой сети является метод обратного распространения ошибки. Его суть заключается в том, что если для одного из обучающих документов получен неправильный ответ на одном из выходов, то ошибка распространяется обратно по сети, и веса связей изменяются для уменьшения ошибки.

Количество промежуточных слоев в нейронной сети может быть динамическим и не задано заранее. В этом случае слои последовательно генерируются динамически до достижения нужного уровня точности.

Сверточная нейронная сеть (CNN) является однонаправленной многослойной сетью, которая использует операцию свертки. При свертке каждый фрагмент входных данных умножается поэлементно на матрицу (ядро) свертки, а полученные значения суммируются и записываются в соответствующую позицию выходных данных. Общая схема сверточной нейронной сети представлена на рисунке 2.

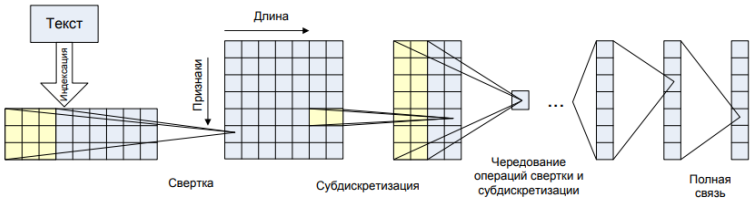

Рисунок 2. Архитектура сверточной нейронной сети

Рекуррентная нейронная сеть (RNN) формируется путем добавления обратных связей к многослойному перцептрону. Одним из широко используемых типов RNN является сеть Элмана, представленная на рисунке 3. В этой архитектуре обратные связи идут не от выхода сети, а от выходов внутренних нейронов. Это позволяет учесть предыдущие состояния наблюдаемых процессов и накопить информацию для формирования правильной стратегии обучения. Одной из ключевых особенностей рекуррентных нейронных сетей является их способность запоминать последовательности.

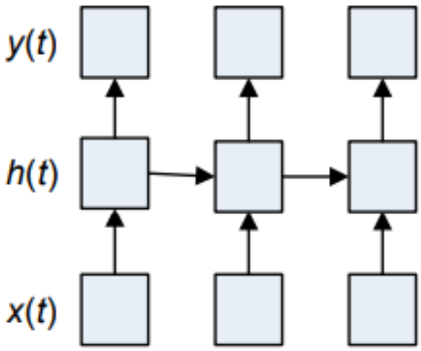

Рисунок 3. Нейронная сеть Элмана

Скрытый слой $h(t)$ в период времени t вычисляется путем преобразования текущего входного слоя $x(t)$ и предыдущего скрытого слоя $h(t1)$. Далее из скрытого слоя $h(t)$ результат поступает на выходной слой $y(t)$.

Преимущества метода:

- имеет очень высокое качество алгоритма при удачном подборе параметров;
- является универсальным аппроксиматором непрерывных функций;
- поддерживает инкрементное обучение.

Недостатки метода:

- вероятность возможной расходимости или медленной сходимости, поскольку для настройки сети используются градиентные методы;
- необходимость очень большого объема данных для обучения, чтобы достичь высокой точности;
- низкая скорость обучения.

1.3. Предобработка и методы векторизации текстовых данных

Предобработка данных является важным этапом в подготовке данных для задач классификации в машинном обучении. В данном разделе будут описаны основные шаги, выполняемые в этом процессе. Основные шаги отображена на графике (см. рис. 6).

- Очистка данных. Первым шагом предобработки данных является очистка данных от шума, выбросов и несущественных элементов. Это включает удаление пунктуации, специальных символов, стоп-слов, а также преобразование текста в нижний регистр.
- Токенизация и приведение к нормальной форме. Далее производится токенизация текста, то есть разбиение текстовых строк на отдельные токены или слова. Это позволяет представить текст в виде последовательности слов или символов, которые могут быть легко обработаны моделью машинного обучения. Также может быть применено приведение слов к нормальной форме, чтобы уменьшить размерность данных и учесть синонимы.
- Удаление стоп-слов и стемминг. Стоп-слова - это общие слова, которые не несут смысловой нагрузки и могут быть исключены из анализа.
- Приведения к векторному виду. Векторизация данных представляет текстовые данные в виде числовых векторов, которые могут быть использованы моделью машинного обучения. В этом разделе будут рассмотрены различные методы векторизации, включая мешок слов (bag-of-words), TF-IDF и эмбеддинги слов.

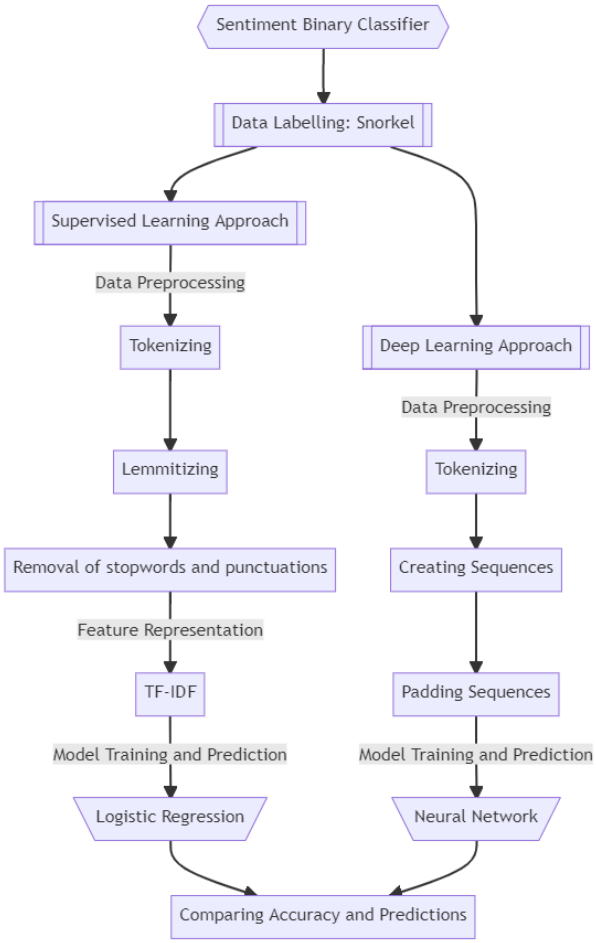

Рисунок 4. Этапы анализа данных

Рассмотрим вышеупомянутые методы векторизации:

- Мешок слов. Для этого составляется список уникальных слов, а после для каждого текста подсчитывается количество упоминаний каждого уникального слова. Такой способо не учитывает порядок вхождения слов.

- Вектора TF-IDF — вектор длины равной количеству уникальных слов, но каждый компонент состоит из 2-х сомножителей:

  – TF (term frequency) — частота встречаемости слова в тексте,

$$TF(x) = \frac{\text{кол-во появления слова в тексте}}{\text{общее кол-во слов в тексте}}$$

  – IDF (inverse document frequency) — логарифм от обратной частоты встречаемости документов с указанным словом, т.е. логарифм от отношения общего кол-ва элементов к общему кол-ву элементов, в котором содержится определенное сло-

во.

$$IDF(x) = \log\left(\frac{\text{общее кол-во документов}}{\text{кол-во документов, содержащих } x}\right)$$

Такой метод полезен при перераспределении весов для часто встречаемых и редких слов.

- Word2vec — представление каждого слова в виде вектора, который содержит информацию о контекстных (сопутствующих) словах.

1.4. Оценка модели

Оценка качества классификации позволяет определить, насколько успешно модель выполняет задачу классификации и предоставляет информацию о ее надежности и эффективности. Для проведения оценки качества классификации требуются обучающая и тестовая выборки. При этом важно правильно подобрать соотношение между размерами этих выборок, чтобы получить объективную оценку.

Если мы сначала находим оптимальные признаки на всей выборке и затем оцениваем качество алгоритма на тестовой выборке, то отобранные признаки уже будут оптимизированы под модель, что может привести к слишком оптимистичной оценке. Поэтому необходимо выбирать соотношение между объемами обучающей и тестовой выборок.

Если обучающая выборка слишком маленькая, оценка качества может быть слишком пессимистичной, так как модель не имеет достаточно данных для обучения. Если тестовая выборка мала, оценка качества может быть неточной, так как она не представляет всю разнообразность данных.

Обычно рекомендуется распределить обучающую и тестовую выборки в соотношении 80:20, то есть 80% данных используются для обучения модели, а 20% для оценки ее качества. Это соотношение обеспечивает достаточное количество данных для обучения и достаточно большую тестовую выборку для надежной оценки.

Для оценки качества классификации существует множество критериев: precision (точность), recall (полнота), accuracy, ROC-AUC, матрица ошибок, F1-score (сбалансированная мера).

Точность (precision) классификации в пределах класса – это доля найденных классификатором документов, действительно принадлежащих данному классу, относительно всех документов, которые система отнесла к этому классу.

Полнота (recall) классификации – это доля найденных классификатором документов, действительно принадлежащих классу, относительно всех документов этого класса в тестовой выборке. Большинство оценок вычисляются из матрицы ошибок размерности 2x2 (см. рис. 7).

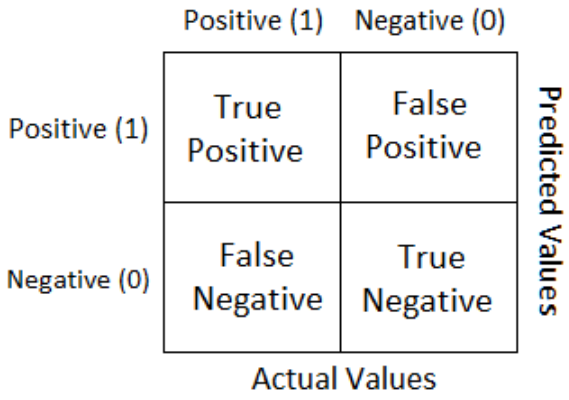

Рисунок 5. Матрица ошибок

В матрице введены следующие условные обозначения:

- TP – истинно положительное решение;
- TN – истинно отрицательное решение;
- FP – ложно положительное решение;
- FN – ложно отрицательное решение.

Согласно определению, вышеупомянутые метрики вычисляется следующим образом:

$$Precision = \frac{TP}{TP+FP}, \quad Recall = \frac{TP}{TP+FN}.$$

Часто можно встретить другую формулу для вычисления точности (accuracy):

$$Accuracy = \frac{\text{кол-во верно выявленных прогнозов}}{\text{общее кол-во прогнозов}} = \frac{TP+TN}{TP+TN+FP+FN}.$$

F-мера – характеристика качества работы алгоритма, которая объединяет в себе информацию о точности и полноте:

$$F1 = \frac{2 * precision * recall}{precision + recall}.$$

ROC-AUC (площадь под ROC-кривой): вероятность того, что случайно выбранный положительный пример будет иметь более высокую оценку, чем случайно выбранный

отрицательный пример. Эта метрика особенно полезна при оценке моделей с несбалансированными классами.

2. Практическая часть

2.1. Сбор данных

В практической части я рассматривал 3 крупномасштабных текстовых наборов данных, который включает различные задачи НЛП, например, классификацию текста, анализ настроений и обнаружение спама. Также были собраны комментарии на казахском языке с YouTube с новостных порталов, ... Детали наборов данных перечислены в Таблице 1.

Таблица 1: Информация о наборе данных

Dataset	Language	Pos	Neg	#Size
yelp_polarity	Engish	1	0	38.000
labeled_tweets	Russian	1	0	226,834
pikabu_comments	Mixed	0	1	14.412
youtube_comments	Kazakh	1	0	10.000

Сбор данных с YouTube осуществлялся посредством извлечения коментариев, имея соответствующую ссылку на видео. Для удобства был составлен список ссылок в одном файле (path_to_links).

Метод *extract_html* у класса **HTML_Extractor** позволяет загрузить страницу с задержкой в *delay* секунд для полной подгрузки комментариев под видео и сохранить соответствующую HTML страницу.

Данные с открытых датасетов на русском, английском языках были разбиты на множество датасетов уменьшенного размера для удобного перевода на казахский язык.

После перевода файлы необходимо было объединить и собрать единый датасет. Т.о., объединение производится в 2 этапа:

- объединение одноименных файлов, которые были разбиты на предыдущем шаге для удобного перевода,
- сбор общего датасета.

Т.о., на выходе получаем датасет, объединяющий 3 открытых датасета на казахском языке.

2.2. Предобработка данных

Этот этап содержит основные этапы предобработки данных для дальнейшего удобного анализа. Одна из возникших проблем, это проблема зашумления текста, генерируемая

пользователем. Проблема заключается по причине быстрого введения неологизмов, и своеобразного написание аббревиатур. Более того, носители более чем одного языка склонны смешивать их, явление использовать транслитерацию (написание ненациональными алфавитами).

Нормализация решала следующие проблемы, задачи:

- спонтанная транслитерация – переключение алфавитов без соблюдения каких-либо особых правил или стандартов, например казахское слово *”біз”* может писаться тремя дополнительными способами: ”биз”, ”быз” и ”biz”;
- использование гомоглифов – взаимозаменяемое использование идентичных или похожих по внешнему виду латинского и кириллического алфавитов, которые, хотя и кажутся идентичными, имеют разные символы Unicode;
- переключение кода – использование русских слов и выражений в казахском тексте и наоборот;
- трансформация слов – чрезмерное дублирование букв, напр. ”керемеет” вместо ”керемет” (великий) или сегментирование слов, напр. ”к е р е м е т”;
- удаление смайлов.

Следующим этапом после нормализации разделение текста на токены, а также удаление знаков препинания и стоп-слов. И заключительным этапом является лемматизация и стемминг - процессы приведения слов к их базовой или начальной форме. Лемматизация учитывает морфологические особенности языка и возвращает слова к их базовой форме. Стемминг, в свою очередь, сокращает слова до их корней. На рисунке 6 можно видеть весь пайлайн предобработки на примере.

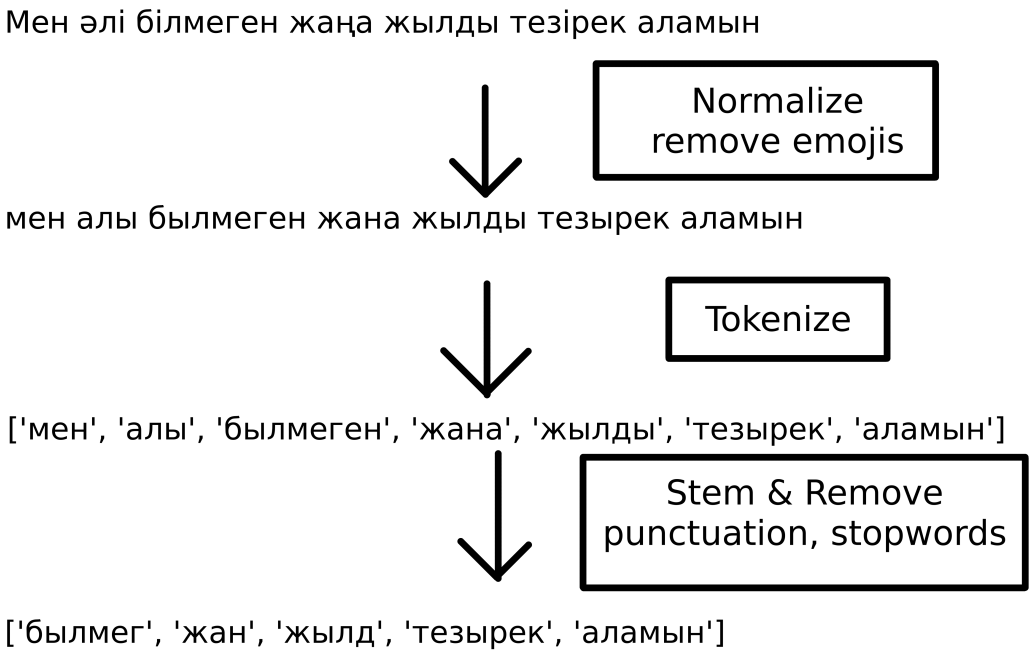

Рисунок 6. Основные этапы предобработки данных

2.3. Векторизация и анализ данных

После приведения данных к нормализированной форме применяется соответсвующий тип векторизации. В качестве примера был выбран метод векторизации, учитывающий частоту появления слова как в определенном тексте, так и во всей выборке (TF-IDF).

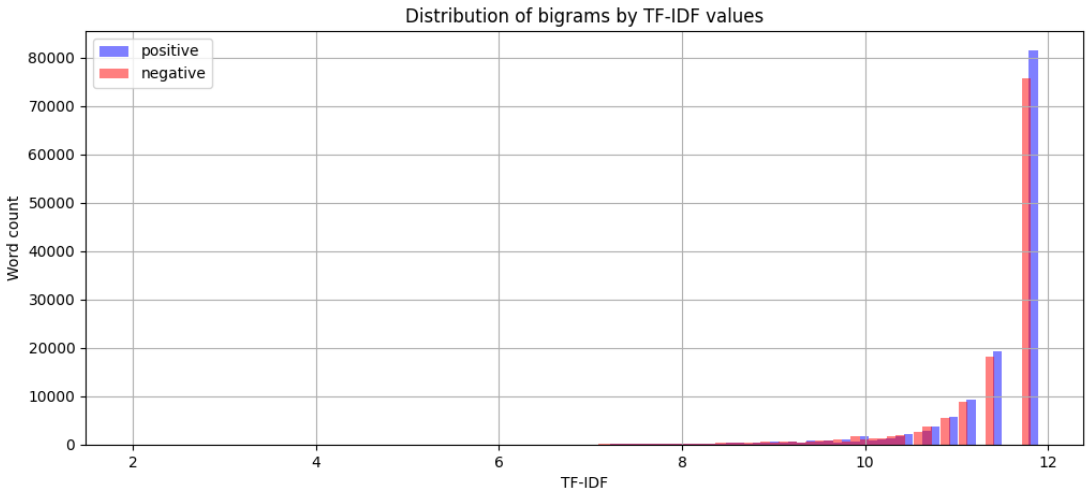

Рисунок 7. Распределение значений TF-IDF векторов

2.4. Оценка модели

Для оценки качества модели анализа тональности текстов на казахском языке были использованы следующие метрики:

- матрица ошибок при разных пороговых значениях разделения двух классов,

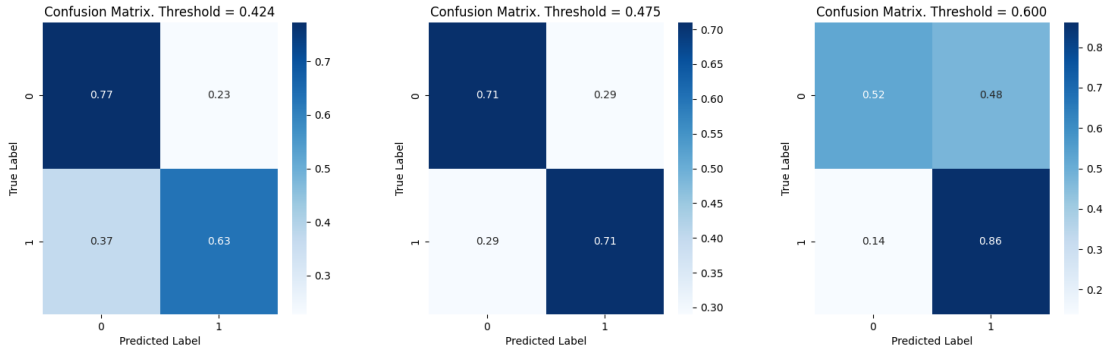

Рисунок 8. Матрица ошибок классификации модели

- ROC-AUC - график зависимости доли истинно положительных результатов *True Positive Rate* от доли ложноположительных результатов *False Positive Rate* при различных порогах классификации.

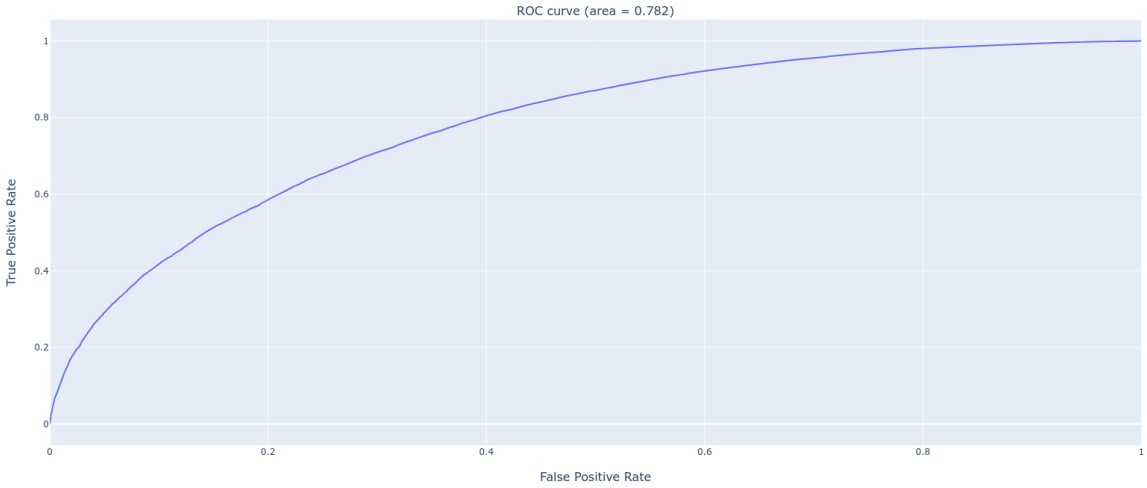

Рисунок 9. ROC-кривая классификации модели

2.5. Результаты

По собранным и предобработанным данным были построены облака слов:

Рисунок 10. Облако слов наиболее частотных, уникальных слов для каждой метки: positive(1), negative(0)

Рисунок 11. Облако слов наиболее важных для классификации каждого класса: positive(1), negative(0)

На основе вышеописанных метрик и графиков можно сделать выводы о качестве модели анализа тональности текстов на казахском языке. Значения метрик свидетельствуют о хорошей точности модели и её способности правильно классифицировать тексты по тональности. Эти результаты подтверждают эффективность выбранных методов и подходов в решении поставленной задачи.

3. Заключение

В данной работе был проведен первоначальный анализ тональности чатов на казахском языке. Исследование включало в себя несколько ключевых этапов, от сбора и предобработки данных до построения и оценки модели машинного обучения. Основные результаты:

- Сбор и подготовка данных: Были собраны данные с различных открытых источников, таких как новостные сайты и комментарии к видео материалам с платформы YouTube, на русском и английском языках. Данные были переведены на казахский язык и подвергнуты предобработке, включающей нормализацию, токенизацию и удаление пунктуации и знаков препинания.

- Построение модели: Были построены облака слов по сырым и предобработанным данным, что позволило визуализировать наиболее часто встречающиеся и важные для классификации слова. Для классификации тональности текста была использована модель логистической регрессии.

- Оценка модели: Модель была оценена с использованием метрик, таких как матрица ошибок и ROC-кривая.

Для дальнейшего развития и улучшения модели предлагается выполнить следующие шаги:

- написание алгоритма для приведения слов к начальной форме (лемматизация) для казахского языка, что поможет улучшить качество предобработки данных,

- векторизация данных с использованием методов embedding, что позволит более точно представлять семантические связи между словами,

- использование трансформеров для построения модели, что может значительно улучшить точность классификации благодаря их способности учитывать контекст слов в предложении.

Список литературы

[1] Andrea G., Matteo M., Alessandro Z., Andrea A. A Survey on Text Classification Algorithms: From Text to Predictions — 2022. — с. 4–14.

[2] Bo Pang, Lillian Lee, Shivakumar Vaithyanathan Thumbs up? Sentiment Classification using Machine Learning Techniques — 2002. — с. 2–5.

[3] Батура Т.В. Методы автоматической классификации текстов — 2017. — с. 87–93.

[4] Gregor H. Parameter estimation for text analysis — 2005. — с. 11–13.

[5] Peter D. Turney Thumbs Up or Thumbs Down? Semantic Orientation Applied to Unsupervised Classification of Reviews — 2002. — с. 2–4.

[6] Russian Text Detoxification Based on Parallel Corpora. URL: https://russe.nlpub.org/2022/tox/

[7] Большакова Е.И., Воронцов К.В., Ефремова Н.Э., Клышинский Э.С., Лукашевич Н.В., Сапин А.С. Автоматическая обработка текстов на естественном языке и анализ данных — 2017. — 269 с.

[8] Aru Omarali Sentiment analysis and visualization of data from social networks using Machine learning algorithms — 2021.

[9] Andrew L., Raymond E. Learning Word Vectors for Sentiment Analysis — 2011. — 4 с.

[10] Altynbek Amiruly Sharipbay, Banu Yergesh, Gulmira Bekmanova Sentiment analysis of Kazakh text and their polarity — 2019.

[11] Tom De Smedt, Guy De Pauw, Pieter Van Ostaeyen Automatic Detection of Online Jihadist Hate Speech: CLiPS Technical Report Series — 2018.

[12] B. Myrzakhmetov, Zh. Yessenbayev and A. Makazhanov Initial Normalization of User Generated Content: Case Study in a Multilingual Setting — AICT 2018.

[13] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin Attention is All You Need — 2017.

[14] Шахпутов А. Разработка программного комплекса, позволяющего автоматизировать процесс оценки устойчивости текстовых моделей машинного обучения к внешним воздействиям — 2023.