Анализ тональности чатов на казахском языке

Курсовая работа

Шахпутов Асылхан Ерболатулы

Научный руководитель:

Смирнов Илья Николаевич

Московский государственный университет имени М. В. Ломоносова Казахстанский филиал
Факультет вычислительной математики и кибернетики

Астана 2024

Содержание

Анализ тональности текста: концепция, методы

Практическая часть

Результаты

Заключение

Литература

Актуальность

В последние годы наблюдается значительный рост использования казахского языка в цифровом пространстве, включая социальные сети, новостные сайты и платформы для обмена видео, такие как YouTube. Несмотря на это, анализ тональности текстов на казахском языке остается недостаточно изученной областью. Основные причины, по которым актуальность данной работы высока, включают:

- недостаток исследований и инструментов,
- рост объемов текстовых данных,
- практическая значимость.

Цель и задачи

Целью данной работы является разработка и реализация методов автоматического анализа тональности текстов на казахском языке. Для достижения поставленной цели были решены следующие задачи:

- исследовать методы анализа текста по тональности,
- сбор и предобработка данных,
- построение модели для определения тональности,
- экспериментальные исследования, оценка модели.

Предобработка и методы векторизации текстовых данных

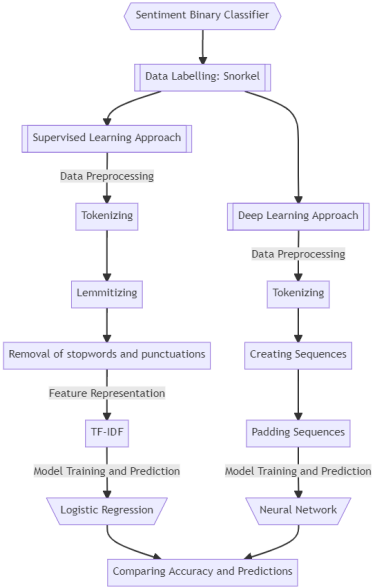

Методы векторизации:

- Мешок слов,
- TF-IDF,
- Embedding.

Векторизация

```
Document 1: "I love dogs and cats"
Document 2: "I hate dogs but love cats"
Document 3: "Dogs are my favorite animal"
```

```
['I', 'love', 'dogs', 'and', 'cats', 'hate', 'but', 'are', 'my', 'favourite', 'animal']
```

	I	love	dogs	and	cats	hate	but	are	my	favorite	animal
Doc 1	1	1	1	1	1	0	0	0	0	0	0
Doc 2	1	1	0	0	1	1	1	0	0	0	0
Doc 3	0	0	1	0	0	0	0	1	1	1	1

Word	TF		IDF	TF*IDF	
	A	B		A	B
The	1/7	1/7	log(2/2) = 0	0	0
Car	1/7	0	log(2/1) = 0.3	0.043	0
Truck	0	1/7	log(2/1) = 0.3	0	0.043
Is	1/7	1/7	log(2/2) = 0	0	0
Driven	1/7	1/7	log(2/2) = 0	0	0
On	1/7	1/7	log(2/2) = 0	0	0
The	1/7	1/7	log(2/2) = 0	0	0
Road	1/7	0	log(2/1) = 0.3	0.043	0
Highway	0	1/7	log(2/1) = 0.3	0	0.043

BOW, TF-IDF

Векторизация

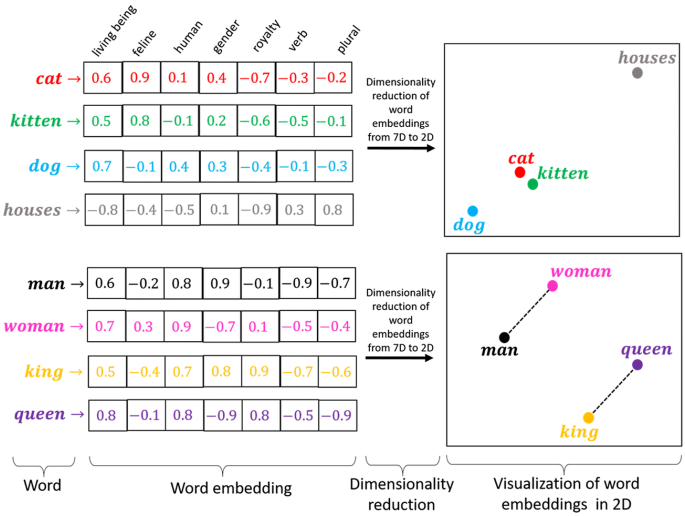

Embedding

Критерий оценки точности/устойчивости

Устойчивость/точность — критерий оценки качества, показывающая на сколько подвержена модель машинного обучения к возмущенным данным.

$$Accuracy = \frac{\text{кол-во верно выявленных прогнозов}}{\text{общее кол-во прогнозов}} = \frac{TP + TN}{TP + TN + FP + FN}.$$

		Positive (1)	Negative (0)
Predicted Values	Positive (1)	True Positive	False Positive
	Negative (0)	False Negative	True Negative
		Actual Values	

ROC-кривая

График содержит:

- *Ось X*: False Positive Rate (FPR) - доля ложноположительных классификаций от общего числа отрицательных примеров: $\frac{FP}{FP+TN}$,
- *Ось Y*: True Positive Rate (TPR) - доля истиннположительных классификаций от общего числа положительных примеров: $\frac{TP}{TP+FN}$.

Интерпретация площади под кривой (AUC):

- $AUC = 1.0$: идеальная модель, идеально различает положительные и отрицательные классы без ошибок;
- $0.7 \leqslant AUC < 1.0$: хорошая модель с высокой способностью различать классы;
- $0.5 \leqslant AUC < 0.7$: модель, имееющую умеренную способность различать классы;
- $AUC = 0.5$: случайная модель не лучше случайного угадывания;
- $AUC < 0.5$: плохая модель. Хуже, чем случайное угадывание.

Сбор данных

Источники:

- открытые датасеты на русском и английских языках,
- комментарии с новостных сайтов,
- комментарии к видео материалам с YouTube.

Dataset	Language	Positive label	Negative label	Size
yelp_polarity	English	1	0	38.000
labeled_tweets	Russian	1	0	226.834
pikabu_comments	Mixed	0	1	14.412
youtube_comments	Kazakh	1	0	10.000

Сбор данных и предобработка

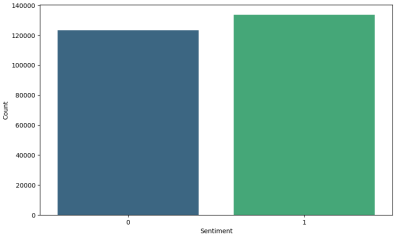

Мен әлі білмеген жаңа жылды тезірек аламын

Normalize
remove emojis

мен алы былмеген жана жылды тезырек аламын

Tokenize

['мен', 'алы', 'былмеген', 'жана', 'жылды', 'тезырек', 'аламын']

Stem & Remove
punctuation, stopwords

['былмег', 'жан', 'жылд', 'тезырек', 'аламын']

Анализ данных

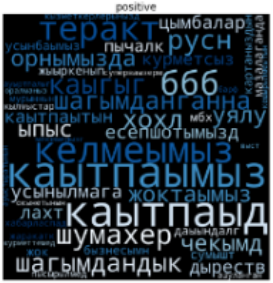

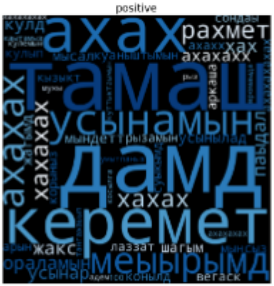

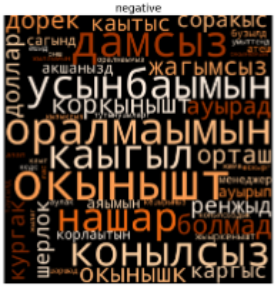

Распределение значений TF-IDF векторов

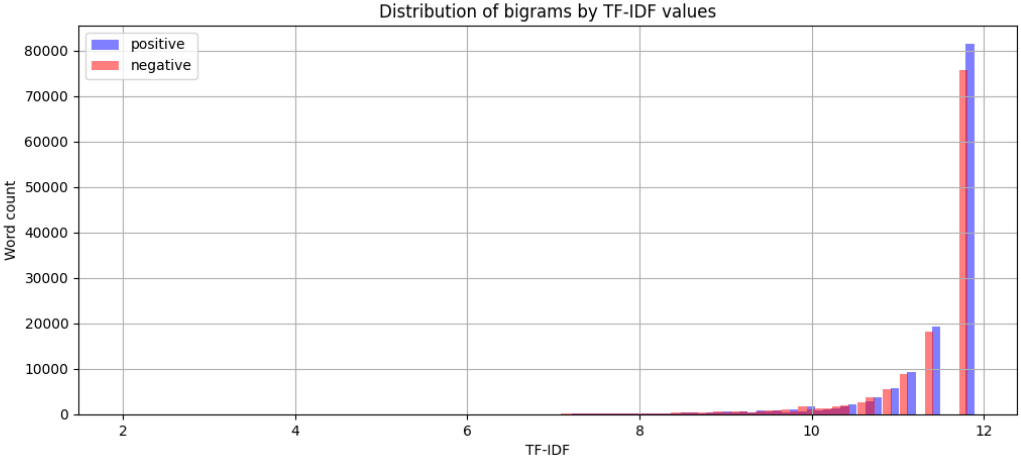

Матрица ошибок

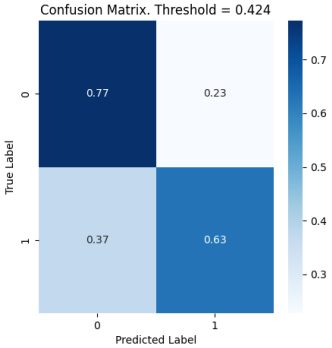

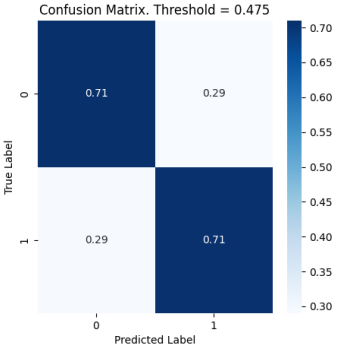

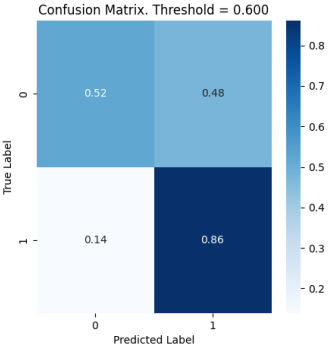

ROC кривая

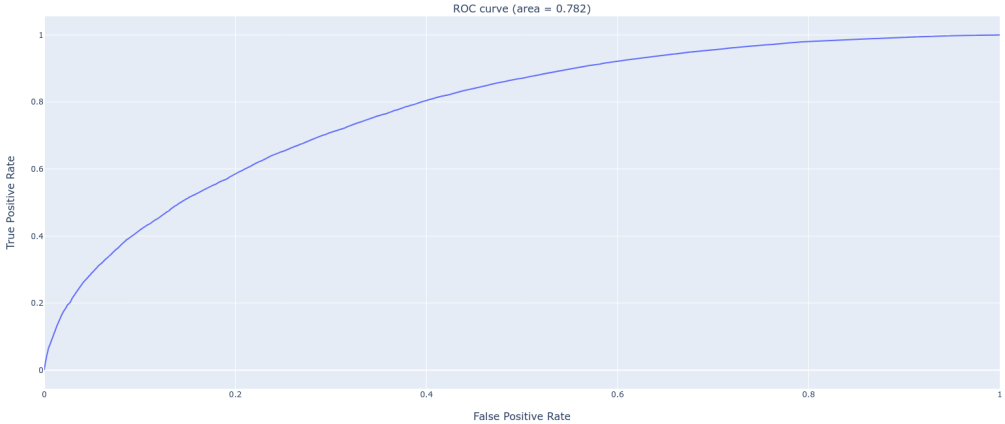
ROC curve (area = 0.782)
True Positive Rate
False Positive Rate
0
0.2
0.4
0.6
0.8
1

Заключение

В рамках курсовой работы были выполнены следующие задачи:

- организован pipeline для сбора, перевода и предобработки данных,
- построена простая модель для классификации размеченных комментариев,
- получены предварительные метрики оценивания.

Дальнейшая работа:

- написание алгоритма для приведения слов к начальной форме (для казахского языка),
- векторизация данных, используя embedding,
- использование трансформера для построения модели.

Список литературы

1. Andrea G., Matteo M., Alessandro Z., Andrea A. A Survey on Text Classification Algorithms: From Text to Predictions — 2022. — с. 4–14.
2. Bo Pang, Lillian Lee, Shivakumar Vaithyanathan Thumbs up? Sentiment Classification using Machine Learning Techniques — 2002. — с. 2–5.
3. Батура Т.В. Методы автоматической классификации текстов — 2017. — с. 87–93.
4. Gregor H. Parameter estimation for text analysis — 2005. — с. 11–13.
5. Peter D. Turney Thumbs Up or Thumbs Down? Semantic Orientation Applied to Unsupervised Classification of Reviews — 2002. — с. 2–4.
6. Russian Text Detoxification Based on Parallel Corpora. URL: https://russe.nlpub.org/2022/tox/
7. Большакова Е.И., Воронцов К.В., Ефремова Н.Э., Клышинский Э.С., Лукашевич Н.В., Сапин А.С. Автоматическая обработка текстов на естественном языке и анализ данных — 2017. — 269 с.
8. Aru Omarali Sentiment analysis and visualization of data from social networks using Machine learning algorithms — 2021.

Список литературы

9 Andrew L., Raymond E. Learning Word Vectors for Sentiment Analysis — 2011. — 4 с.

10 Altynbek Amiruly Sharipbay, Banu Yergesh, Gulmira Bekmanova Sentiment analysis of Kazakh text and their polarity — 2019.

11 Tom De Smedt, Guy De Pauw, Pieter Van Ostaeyen Automatic Detection of Online Jihadist Hate Speech: CLiPS Technical Report Series — 2018.

12 B. Myrzakhmetov, Zh. Yessenbayev and A. Makazhanov Initial Normalization of User Generated Content: Case Study in a Multilingual Setting — AICT 2018.

13 Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin Attention is All You Need — 2017.